

Clasificación multi-clase de artículos de la BBC mediante fine-tuning de BERT

Juan Manuel Gómez Cárdenas, Andrés Javier Rambal Vecino, Ricardo Andrés Pabón Masapanta

I. INTRODUCCIÓN

La clasificación automática de noticias es una tarea clásica de Procesamiento del Lenguaje Natural (PLN) con aplicaciones en organización editorial y recomendación de contenidos. Los modelos recurrentes dominaron esta tarea durante años, pero su naturaleza secuencial limita la captura de dependencias largas [4]. La introducción de la auto-atención en el *Transformer* [1] cambió el panorama al permitir el procesamiento paralelo de secuencias y modelar relaciones de largo alcance. Sobre esa arquitectura, BERT [2] introdujo un preentrenamiento bidireccional con *Masked Language Modeling* cuyas representaciones contextuales transfieren bien a tareas *downstream* mediante *fine-tuning*.

En este trabajo abordamos la clasificación de artículos del dataset *BBC News* [5] en cinco categorías temáticas (*business*, *entertainment*, *politics*, *sport*, *tech*) mediante fine-tuning de *bert-base-uncased* con una cabeza lineal y activación softmax, conforme a lo pedido para este micro-proyecto. Aportamos: (i) un *pipeline* reproducible BERT→BertForSequenceClassification con la librería *transformers* [6]; (ii) una evaluación cuantitativa y cualitativa por clase con matriz de confusión; (iii) un estudio de sensibilidad a la tasa de aprendizaje, hiperparámetro central del fine-tuning de transformers [2].

II. METODOLOGÍA

Datos. *BBC Articles Dataset* [5] con 2225 artículos en cinco clases razonablemente balanceadas (Fig. 1). El EDA muestra una mediana de 421 *tokens* BERT por artículo y un percentil 95 de 913, por encima del límite duro (Hard Limit) de 512 de BERT. Aplicamos limpieza ligera (saltos de línea y espacios), preservando mayúsculas y puntuación porque la tokenización *WordPiece* las explota. Codificamos las etiquetas con un mapa explícito *label2id/id2label* y partimos el corpus de manera estratificada en *train/val/test* con tamaños 1557/334/334.

Arquitectura. BertForSequenceClassification carga *bert-base-uncased* (12 capas, 110 M parámetros) y añade sobre el *embedding* del token [CLS] un *pooler*, un Dropout y una capa lineal $768 \rightarrow 5$. La activación softmax y la *CrossEntropy* se aplican internamente en la API, alineando la implementación con el Micro-proyecto. Justificamos BERT sobre alternativas más ligeras (DistilBERT del laboratorio) por su mayor capacidad y mejor preentrenamiento [2], y la variante *uncased* porque el dominio periodístico no depende de mayúsculas para distinguir clases.

Tokenización y entrenamiento.
padding="max_length", truncation=True,




Fig. 1. Distribución de clases en BBC News. Máx/mín ≈ 1.32 , suficientemente balanceado para reportar métricas *macro* y por clase sin re-balanceo.

max_length=256; cubre el *lead* periodístico –donde se concentra la señal temática– a un cuarto del coste de max_length=512. Fine-tuning end-to-end con AdamW (weight decay 0.01, exceptuando bias y LayerNorm), lr principal 2×10^{-5} , linear schedule with warmup (10%), batch size 16, gradient clipping a norma 1.0 y 3 épocas (rango 2–5 sugerido). Seed fijado en 42; conservamos el checkpoint con mejor F1 *macro* de validación. Para evaluar sensibilidad, replicamos el experimento con $lr=5 \times 10^{-5}$. Métricas reportadas: accuracy, precision, recall y F1 (macro y por clase) sobre test, complementadas con la matriz de confusión. Usamos F1 *macro* como criterio principal por ser insensible al desbalance leve.

III. RESULTADOS

Desempeño global. La configuración principal alcanza en test accuracy = 0.9910 y F1 macro = 0.9909 con loss = 0.0394 (Tabla I); de los 334 artículos solo 3 se clasifican mal. La variante con $lr=5 \times 10^{-5}$ alcanza un F1 de validación máximo más alto (0.994 vs. 0.988) y converge antes, pero produce las mismas 3 predicciones erróneas en test – el dataset está cerca de la saturación y el margen se manifiesta en confianza, no en aciertos.

TABLE I
COMPARACIÓN DE CONFIGURACIONES (BERT-BASE, 3 ÉPOCAS).

Config.	Val F1 máx	Test acc.	Test F1 macro	Test loss
lr= 2×10^{-5}	0.9878	0.9910	0.9909	0.0394
lr= 5×10^{-5}	0.9936	0.9910	0.9909	0.0458

Curvas y resultados por clase. La Fig. 2 muestra que la loss de entrenamiento desciende de 0.85 a 0.035 mientras

la de validación se estabiliza en ~ 0.05 ; la brecha train/val al final es < 0.6 p.p. en F1, sin sobreajuste pronunciado. Por clase, *entertainment* y *sport* se clasifican perfectamente ($F1=1.0$) gracias a un léxico altamente específico y consistente. Las clases más frágiles son *tech* ($F1=0.984$; $recall=1.0$ pero $precision=0.968$) y *politics* ($F1=0.984$; $precision=1.0$ pero $recall=0.968$). El patrón es asimétrico: *tech* atrae falsos positivos (al modelo le tienta clasificar como *tech* cuando el léxico tecnológico es saliente) mientras que *politics* pierde muestras hacia *business* y *tech*. Mejor clase: *entertainment*; peor clase: *tech*.




Fig. 2. Curvas de pérdida (izq.) y F1 macro (der.) por época. La validación supera al entrenamiento en la época 1 por el efecto regularizador del Dropout en *train*.

Resultados cualitativos. Aciertos prototípicos con probabilidad softmax ≈ 0.99 (e.g. una nota sobre los Oscar etiquetada *entertainment*, $p=0.9909$). Los tres errores absolutos del modelo en *test* son temáticamente creíbles y comparten un patrón común –la frontera *politics/business/tech*–: (i) “UK pledges £1bn to vaccine effort” (real *politics* $\rightarrow$ pred. *business*, $p=0.555$); (ii) “UK firms embracing e-commerce” (*politics* $\rightarrow$ *tech*, $p=0.851$); (iii) “Card fraudsters targeting web” (*business* $\rightarrow$ *tech*, $p=0.885$). En los tres, la etiqueta predicha es una lectura editorial igualmente defendible. Además, el caso de menor confianza absoluta del *test* ($p=0.555$) coincide con un error, y los siguientes dos casos más dudosos ($p \approx 0.81$ – 0.82) son aciertos –el softmax actúa como un detector calibrado de ambigüedad y sugiere que un umbral de rechazo $p < 0.6$ capturaría los fallos genuinos sin descartar muchos aciertos (Fig. 3).




Fig. 3. Matriz de confusión en *test* (BERT-base, $lr=2 \times 10^{-5}$): solo 3 errores de 334 muestras.

IV. DISCUSIÓN

Interpretación. El F1 macro de 0.991 confirma que el preentrenamiento bidireccional de BERT [2] sobre Wikipedia y BookCorpus transfiere de forma efectiva al dominio periodístico de la BBC: tres épocas de fine-tuning sobre 1 557 muestras bastan para capturar la semántica temática. Las dos configuraciones ($lr=2 \times 10^{-5}$ y 5×10^{-5}) producen las mismas 3 predicciones erróneas en *test* con únicamente diferencias en la calibración del softmax, lo que indica que el dataset está cerca del techo del benchmark. Los errores residuales no son ruido del modelo sino ambigüedad genuina en la frontera *politics/business/tech*, donde la etiqueta canonica de la BBC no es la única lectura razonable.

Conexión con la teoría. Las curvas no muestran sobreajuste clásico (*val_loss* creciente) en 3 épocas y la *val_loss* aún descende en la última -2 épocas extra exprimirían un margen marginal– pero el ratio capacidad/datos (110 M parámetros vs. 1 557 muestras) hace que un horizonte de más de 5 sí deterioraría la generalización; coincide con la recomendación de [2] de mantener el fine-tuning corto. El estudio de *lr* ilustra el clásico compromiso sesgo-varianza: 5×10^{-5} tiene mayor varianza pero llega antes al mínimo; 2×10^{-5} es más conservador. La saturación en *test* indica que la capacidad del modelo excede la complejidad de la tarea –escenario propicio para *distillation*. Adicionalmente, el softmax actúa como un detector calibrado de ambigüedad: el único error con probabilidad < 0.6 coincide con el caso de menor confianza absoluta del *test*, sugiriendo que un umbral de rechazo $p < 0.6$ sería un mecanismo simple de *abstention* en producción.

Limitaciones y mejoras. (i) Dataset pequeño de un solo medio: el modelo aprende sesgos editoriales británicos. (ii) Truncar a 256 *tokens* ignora $\sim 50\%$ del contenido en artículos largos. (iii) Solo se evaluó un *seed*; promediar 3–5 daría intervalos más robustos. (iv) Cinco categorías amplias hacen la tarea relativamente sencilla. Mejoras propuestas: *Hierarchical Transformers* para procesar artículos completos, *distillation* a DistilBERT, y variantes preentrenadas con *span corruption* como T5 [3] que han mostrado mejoras consistentes en transferencia text-to-text.

REFERENCES

- [1] A. Vaswani *et al.*, “Attention Is All You Need,” in *Adv. Neural Inf. Process. Syst. (NeurIPS)*, 2017.
- [2] J. Devlin, M.-W. Chang, K. Lee, and K. Toutanova, “BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding,” in *Proc. NAACL-HLT*, 2019, pp. 4171–4186.
- [3] C. Raffel *et al.*, “Exploring the Limits of Transfer Learning with a Unified Text-to-Text Transformer,” *J. Mach. Learn. Res.*, vol. 21, no. 140, pp. 1–67, 2020.
- [4] L. Tunstall, L. von Werra, and T. Wolf, “Recurrent Neural Networks vs. Transformers,” in *Natural Language Processing with Transformers*, O’Reilly, 2022.
- [5] J. Ferretti, “BBC Articles Dataset,” Kaggle, 2023. [Online]. Available: kaggle.com/datasets/jacopoferretti/bbc-articles-dataset
- [6] T. Wolf *et al.*, “Transformers: State-of-the-Art Natural Language Processing,” in *Proc. EMNLP: System Demonstrations*, 2020, pp. 38–45.